


Prírodovedecká fakulta Univerzity Karlovej

Katedra aplikovanej geoinformatiky a kartografie



Algoritmy počítačovej kartografie

Zadanie č. 2: Generalizovanie budov

Bc. Filip Kradijan Seider

Bc. Peter Dúbrava

2023/2024

L^AT_EX

Zadanie

Vstup: množina budov $B = \{B_i\}_{i=1}^n$, budova $B_i = \{P_{i,j}\}_{j=1}^m$.

Výstup: $G(B_i)$.

Zo súboru vyberiete vstupné údaje, ktoré predstavujú lomové body budov, a zovšeobecniť budovy na

- Minimum Area Enclosing Rectangle,
- PCA.

Pri prvej metóde použite jeden z algoritmov na konštrukciu konvexného trupu. Pri generalizácii budovy na úroveň LOD0 nahraďte budovu obdĺžnikom orientovaným v oboch hlavných smeroch so stredom v strede budovy, jeho plocha bude rovnaká ako plocha budovy. Výsledky generalizácie vhodne vizualizujte.

Otestujte a porovnajte účinnosť oboch metód pomocou hodnotových kritérií. Pokúste sa rozhodnúť, pre ktoré tvary budov poskytujú metódy nevhodné výsledky a pre ktoré poskytujú vhodnú aproximáciu.

Úloha	Hodnotenie
Generalizovanie budov metódami Minimum Area Enclosing Rectangle a PCA	15b
Generalizovanie budov metódou Longest Edge	+5b
Generalizovanie budov metódou Wall Average	+8b
Generalizovanie budov metódou Weight Bisector	+10b
Implementovanie ďalších metód tvorby konvexnej obálky	+5b
Ošetrenie singulárnych prípadov pri generovaní konvexnej obálky	+2b
Spolu	45b

Problematika

Geoinformatika je vedná, ale aj technická disciplína, ktorá sa zaoberá používaním metód a vývojom aplikácií na riešenie geografických problémov. Hlavný dôraz je pritom kladený na určovanie polohy objektov v priestore a ich následné spracovanie v digitálnej podobe. Za týmto účlom je potrebné preskúmať a zaznamenať celý svet. To však prakticky nie je možné z viacerých dôvodov, pričom sa hlavne jedná o veľký nárok na výpočtovú techniku, či úložný priestor. Podobne ako napríklad v analógovej kartografii, kedy v závislosti od mierky, či jej obsahu, dochádza kvôli výpovednej hodnote a čitateľnosti mapy ku zjednodušovaniu tvaru objektov. Tomuto procesu sa nevyhneme ani v súčasnej dobe.

Generalizácia je dôležitým nástrojom v geoinformatike a kartografii, ktorý umožňuje efektívne spravovať, analyzovať a vizualizovať geografické údaje v rôznych kontextoch a aplikáciách. Pri budovách sa stretávame so skratkou LOD (level of details) definujúcou množstvo detailov reálnych objektov sveta, od hrubých obrysov až po sofistikované 3D modely (3DBuildings, 2020).

Prvá úroveň je LOD0 a predstavuje 2,5D digitálny model povrchu. LOD1 je kvádrový model budovy bez strešných štruktúr a bez textúry. Obohatením o strechu získavame LOD2. LOD3 je vytvorený pridaním architektonických informácií s detailami múrov a zobrazením menších štruktúr na strechách. Posledný je model LOD4, ktorý obsahuje všetky informácie o budove, vrátane jej interiéru. Spomína sa už aj LOD5, ktorá ale opisuje napríklad vlastnosti materiálov, stavebné metódy a požiadavky na údržbu (Trhan, 2017).



Figure 1: Znáozornenie detailu jednotlivých úrovní

Konvexná obálka

Konvexná obálka (H), po anglicky convex hull, je jedna z narozšírenejších štruktúr v počítačovej geometrii, ktorá má svoje využitie samostatn, ale aj ako nástroj na vytváranie ďalších štruktúr (Rourke, 2005). Už podľa slovíčka konvexný usudzujeme, že spojnice medzi ľubovoľnými dvoma bodmi leží úplne vnútri tejto množiny. Konvexná obálka (H) môže existovať v ľubovoľnom priestore R^d , ktorý má d rozmerov, kde d je prirodzené číslo. Avšak v tomto prípade budeme špecificky skúmať konkrétnu variantu v dvojrozmernom priestore, R^2 , teda v rovine ($p_i = [x_i, y_i]$). Táto konkrétna verzia konvexnej obálky sa obmedzuje na prácu v rovine, kde sú objekty reprezentované dvojrozmernými súradnicami. Ďalej je definovaná aj ako konečná množina S predstavujúca :

- konvexný mnohoúhelník P s najmenšou plochou,
- priesečnicu všetkých polrovín obsahujúcich P ,
- spojnicu všetkých trojuholníkov, ktorých vrcholy tvoria body P .

Využíva sa napríklad pri analýze tvaru objektu, vytváraní najmenšieho možného obdĺžnika obklopujúceho nejaký objekt (detekcia tvaru a otočenia objektu), detekcii kolízií (pohyb robotov), či analýze zhlukov (Bayer, 2024).

Jej zostrojenie je možné hneď viacerými spôsobmi, pričom nie všetky metódy je možné rozšíriť do vyššej dimenzie. Metódy majú rôzne výhody a nevýhody v závislosti na rozložení a množstve bodov, ale aj ďalších faktoroch. Napríklad rýchlosť tvorby konvexnej obálky s metódou Jarvis Scan je rýchlejšia pri menej komplexných dátach, zatiaľ čo Grahamov Scan, je efektívnejší pre veľké datasety. Práve na tieto dve metódy sa pozrieme bližšie a porovnáme si ich (Violentyev, 2020).




Figure 2: Tvorba konvexnej obálky

Graham Scan

Algoritmus Graham Scan podstatne zmenil výpočtovú geometriu poskytnutím riešenia problému konvexného obalu s vynikajúcou časovou zložitou $O(n \log n)$, kde n je počet vstupných bodov. Začína výberom dolného bodu (pivot q), typicky toho s najnižšou Y súradnicou, pretože je zaručené, že bude súčasťou konvexného obalu. Môže ale nastať situácia, že existuje viacero bodov s rovnakou súradnicou Y , preto je potrebné hľadiť aj na minimálnu hodnotu X ,

$$\min_{\forall p_i \in S} = (x_i, y_i).$$

Potom zostávajúce body usporiada podľa ich uhlov vzhľadom na tento dolný bod a horizontálnu os. Ďalej prechádza týmito usporiadanými bodmi v protismeru hodinových ručičiek. Každý bod je pridaný do zásobníka, ak spĺňa podmienku ľavotočivosti s predchádzajúcimi dvoma bodmi v zásobníku. Pokiaľ to nespĺňa, tak sa vrátíme o krok späť a daný bod už nebudeme používať. Tento proces efektívne konštruuje konvexný obal (Rourke, 1997; Violentyev 2020).

$$p_j = \begin{cases} \notin \mathcal{H}, & p_{i+1} \in (p_i, p_{j+1}), \\ ? \in \mathcal{H}, & p_{j+1} \in (p_j, p_{j+1}). \end{cases}$$




Figure 3: Princíp fungovania Graham Scan

Jarvis Scan

Tento algoritmus je v odbornej literatúre označovaný aj ako Jarvis March, či Gift Wrapping Algorithm. Vo všeobecnosti platí, že je populárnou, jednoduchou a ľahko implementovateľnou metódou, ktorá má ale kvadratickú časovú zložitosť $O(n^2)$, čo robí tento algoritmus neefektívny v komplexnej sade dát. Funguje systematickým obaľovaním sady bodov do najmenšieho možného konvexného mnohoúhelníka. Proces začína výberom počiatočného bodu (pivot q) ako súčasť konvexného obalu,

$$y_i = \min_{\forall p_i \in S} .$$

Následne postupne pridáva nové body otáčaním okolo existujúcich bodov, pričom vyhľadáva maximálny úhol ω_{max} medzi poslednou (p_{j-1}, p_j) a nasledujúcou hranou (p_j, p_{j+1}) konvexnej obálky. Na nájdenie bodu (p_{j+1}) nasledujúcej hrany je potrebné prejsť všetky body, ktoré ešte nie sú súčasťou obálky (Bayer, 2024; Berg, 2008).




Figure 4: Princíp Jarvis Scan

Singulárne prípady

Extrémne body množiny sú vrcholy konvexného obalu, kde je vnútorný uhol menší ako π . Bod je extrémny vtedy, pokiaľ je možné vytvoriť medzi ním a všetkými ostatnými bodmi pomyselnú úsečku, ktorá nepretína konvexný obal (obsahujúci tento skúmaný bod). Počet extrémnych (vrcholových) bodov musí spĺňať nejaké parametre. Keďže potrebujeme vytvoriť polygón, a nie len priamku, tak na vznik polygónu (roviny) sú potrebné minimálne tri body (Rourke, 1997). Okrem toho je potrebné definovať konvexný mnohoúhelník P , ktorého všetky vnútorné uhly sú konvexné a všetky jeho uhlopriečky ležia v jeho vnútri (Bayer, 2024).

Hlavný smer budov

Hlavným problémom pri kartografickej generalizácii budov je zachovanie orientácie budovy. Pred a po generalizácii musí mať budova zachovanú orientáciu vzhľadom na ostatné prvky mapy, ako sú napríklad uličné čiary. Je nevyhnutné identifikovať tzv. hlavné smery budovy, ktoré sú navzájom kolmé a popisujú jej orientáciu. Uchovanie týchto informácií je kľúčové pre zachovanie čitateľnosti a interpretácie mapy, ako aj pre ďalšie aplikácie, ako je analýza priestorových vzťahov. Detekcia a správne určenie hlavných smerov budovy prispieva k presnejšiemu a kvalitnejšiemu výsledku procesu generalizácie. Za týmto účelom bolo vytvorené viacero algoritmov, ktoré si následne podrobnejšie rozoberieme (Bayer, 2024).

Minimum Area Enclosing Rectangle

Často označovaný aj ako Smallest area enclosing rectangle, spočíva v postupnom otáčaní obdĺžnika, ktorý sa zmenšuje (aproximuje) každým krokom, pokiaľ sa jeho plocha nezmenší natoľko, že sa stane najmenším obáľkovým obdĺžnikom. Zároveň však platí, že jeho jedna hrana musí byť kolineárna s úsekom konvexného obalu. Pri tomto algoritme sa ale stretávame s numerickou nepresnosťou v dôsledku kumulácie chýb. Tieto chyby sú zapríčinené obdĺžnikovým tvarom budov (polygónov), v dôsledku čoho sú okraje obdĺžnika totožné s viacerými segmentmi konvexného obalu.

Algoritmus hľadá minimálny uhol φ , o ktorý bude obdĺžnik otočený. Tento uhol je zvieraný hranami najmenšieho obáľkového obdĺžnika a hranami konvexného obalu v bode ich kontaktu V_j , ktorý je taktiež začiatkom kolineárneho segmentu. Pokiaľ nie je súčet týchto minimálnych uhlov menší ako $\frac{\pi}{2}$, tak porovnávame plochu obdĺžnikov s hodnotou minimálnej plocha inicializovanej do ∞ , až kým na nenájde obdĺžnik s minimálnou plochou. Platí, že vrcholy (M_j) a hrany najmenšieho obáľkového obdĺžnika sú orientované v smere hodinových ručičiek (Bayer, 2008).




Figure 5: Princíp Minimum Area Enclosing Rectangle

PCA

Analýza hlavných komponentov (*PCA*) je metóda využívajúca strojové učenie na zjednodušenie veľkej dátovej sady na menšiu, pričom stále obsahuje väčšinu informácií o premenných z pôvodnej sady. Zníženie počtu premenných síce vedie ku menšej presnosti, čo sa ale vynahradí zjednodušením celej sady. Takéto dátové sady bez nepotrebných premenných sú ľahšie na prehľadávanie, čo zjednodušuje analýzu a urýchľuje proces algoritmov. Hlavné komponenty sú teda nové premenné, ktoré vznikli lineárnymi kombináciami pôvodných premenných. Informácie z pôvodných premenných sú najviac koncentrované v prvých komponentoch (Jaadi, 2024). Jeho nevýhodou je, že má nízku efektivitu pri pravidelných objektoch (štvorec, kružnica) (Bayer, 2024).




Figure 6: Hlavný sme s využitím PCA

Pre nájdenie hlavných smerov sa využíva singulárny rozklad (*SVD*) na faktorizáciu kovariačnej matice do troch matíc. Kovariačná matica je symetrická ($p \times p$), kde p predstavuje počet dimenzií a jej úlohou je zistiť vzťahu medzi prvkami dátovej sady, pričom platí, že $C(A, B) = \frac{1}{n-1} \sum_{i=1}^n (A_i - \mu_A) - (b_i - \mu_B)$,

$$C = \begin{bmatrix} C(A, A) & C(A, B) \\ C(B, A) & C(B, B) \end{bmatrix}.$$

Singulárnym rozkladom tak dostaneme $C = U \Sigma V^T$, čo sa dá rozpísať následovne,

$$\begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix} = \begin{bmatrix} u_{11} & u_{12} \\ u_{11} & u_{12} \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} \begin{bmatrix} v_{11} & v_{12} \\ v_{11} & v_{12} \end{bmatrix}.$$

Matica U predstavuje vlastné vektory $C \cdot C^T$, matica V^T taktiež vlastné vektory $C^T \cdot C$ a matica Σ veľkosť vlastných vektorov (singulárne hodnoty),

$$U = V \equiv \begin{bmatrix} \cos\sigma & -\sin\sigma \\ \sin\sigma & \cos\sigma \end{bmatrix},$$

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} = \begin{bmatrix} \sqrt{\lambda_1} & 0 \\ 0 & \sqrt{\lambda_2} \end{bmatrix}.$$

Množina P sa následne otočí o uhol $\pm\omega$ pričom platí,

$$P_0 = P \cdot V,$$

$$P = V^{-1} \cdot P.$$

Wall Average

Táto metóda je pomerne robustná vzhľadom na rôzne tvary budov a ich stien. Avšak je citlivá na uhly, ktoré sú veľmi odlišné od hlavných orientácií. Podľa Bayera (2024) sa najprv určia smernice všetkých hrán a vypočítajú sa v každom vrchole vnútorné uhly $\omega_i = |\sigma_{i,i-1} - \sigma_{i,i+1}|$ medzi smernicou a hranou. Následne sa aplikuje operácia $\text{mod}(\frac{\pi}{2})$, vďaka čomu je každá strana budovy zarovnaná za účelom zjednodušej geometrickej analýzy a porovnávania stien.

Dostaneme tak vzťah $k_i = \frac{2*\omega_i}{\pi}$, ktorý sa ďalej použije na zistenie orientovaného zvyšku po delení podľa vzorca $r_i = (k_i - \lfloor k_i \rfloor) * \frac{\pi}{2}$. Nakoniec sa na určenie hlavného smeru budovy vypočíta vážený priemer, do ktorého stupuje orientovaný zvyšok a váhy (s_i) v podobne dĺžky jednotlivých strán budovy,

$$\sigma = \sigma_{1,2} + \sum_{i=1}^n \frac{r_i s_i}{s_i}.$$




Figure 7: Znazornenie Wall Average

Weight Bisector

Bayer (2024) uvádza, že Weighted Bisector algoritmus je používaný pre hľadanie hlavného smeru objektu v rovine pomocou dvoch najdlhších uhlopriečok, ktoré nepretínajú hranice polygónu. Pri jeho výpočte do rovnice váženého priemeru vstupujú smernice (σ_1, σ_2) a dĺžky týchto uhlopriečok (S_1, S_2) , ktoré predstavujú váhy,

$$\sigma = \frac{S_1 * \sigma_1 + S_2 * \sigma_2}{(S_1 + S_2)}.$$




Figure 8: Princíp Weight Bisector

Longest Edge

Prvý hlavný smer budovy je určený najdlhšou stranou budovy, druhý hlavný smer je na ňu kolmý. Táto metóda však nedosahuje príliš dobrých výsledkov. Je to zapríčinené tým, že najdlhšia strana nemusí vždy reprezentovať hlavný smer. Na druhej strane ale poskytuje určité indikácie o jej tvare a orientácii (Bayer, 2024).




Figure 9: Longest Edge algorimus

Implementovanie

Po priblížení problematiky a vysvetlení metód na jej riešenie je ďalším krokom v tomto zadaní tvorba užívateľského prostredia, v ktorom bude možné demonštrovať rôzne prístupy ku generalizovaniu tvaru budov v troch rôznych lokalitách. Tieto lokality sa od seba odlišujú hustotou, ale aj komplexnosťou tvaru budov. Pre dataset historickej časti mesta bola zvolená Horná ulica v Banskej Bystrici (BB), pre intravilán (sídliisko) bolo v rámci BB vybrané Uhlisko a ako zdroj budov v izolovanej zástavbe bola oblasť lazov nad Hriňovou, ktoré predstavujú roztrúsenú sídelnú zástavbu.

Vstupné dáta

Naše dáta bolo možné získať v troch rôznych formátoch (ESRI GDB, GML a GeoPackage) zo stránky geoportálu. Dátová sada INSPIRE - Budovy je súčasťou celoslovenskej geografickej databázy ZBGIS. Vytvorenie ZBGIS prebieha v troch fázach: fotogrametrické vyhodnotenie leteckých snímok, doplnenie, ale aj revidovanie v teréne a kontrola kvality podľa ISO noriem. Kvalita údajov je definovaná presnosťou geomet-

rie, správnosťou atribútov, kompletnosťou a topológiou. Geometrické dáta môžu byť získavané geodetickými alebo fotogrametrickými metódami, pričom sa preferuje presnejšia metóda.

Druhým alternatívnym zdrojom dát by mohol byť Google Earth Engine, kde bolo možné získať Microsoft Building Footprint Data. Obrisy budov boli vytvorené použitím hlbokým neurónovým sieťam a AI zo záznamov Bing, pričom bol využitý algoritmus na polygonizáciu. Nevýhoda týchto dát bola v tom, že pre územie historickej časti mesta zhlukovala budovy do jedného, veľmi nerealistického polygónu. Ďalej treba spomenúť, že v Google Earth Engine je potrebné dodatatočné programovanie.



Figure 10: Chybné polygóny budov v historickej časti mesta

Keďže stiahnuté dáta obsahovali všetky budovy v republike, tak ich bolo potrebné vyfiltrovať iba na územie nášho záujmu. Za týmto účelom boli vytvorené 3 polygónové vrstvy v oblasti Hriňovských lazov, Uhliska (BB) a Námestia SNP (BB). Následne sme pomocou funkcie intersect vybrali len tie budovy, ktoré boli prienikom našich dvoch vrstiev. Súradnice boli v súradnicovom systéme WGS84 a bolo ich potrebné transformovať na S-JTSK. To bolo docielené zvolením súradnicového systému pri exportovaní našich budov do GeoJSON.



Figure 11: Filtrovanie budov

Aplikácia

Grafické užívateľské prostredie (GUI) aplikácie pozostávalo z okna, lišty a panelu obsahujúceho ikony, ktoré bolo vytvorené za pomoci knižnice QT (v.4.6.1) a jeho funkcionality bolo ďalej dopĺňované za pomoci programovacieho jazyka Python 3.11. Vďaka tomu bolo možné pre jednotlivé ikony pridať aj ich funkcie.

Celkovo bolo použitých 11 ikon (obr. 6), ktorých úlohou je urýchliť prácu používateľa, vďaka čomu nie je potrebné prechádzať lištu a hľadať jednotlivé procesy, ktoré by sme pri väčšej komplexnosti aplikácie mohli prehliadnuť.

Aplikácia dáva používateľovi na výber z piatich analytických metód, ktoré sa spustia hneď po kliknutí na príslušnú ikonu. Keď sa používateľ rozhodne pre použitie iného algoritmu, tak sa výsledky automaticky preklesia. Po spustení algoritmu vybehne pop-up okno s textom, či bolo možné uskutočniť našu metódu na všetkých budovách. Okrem toho pop-up okno slúži aj na zobrazenie efektivity detekcie hlavných smerov a po zatvorení

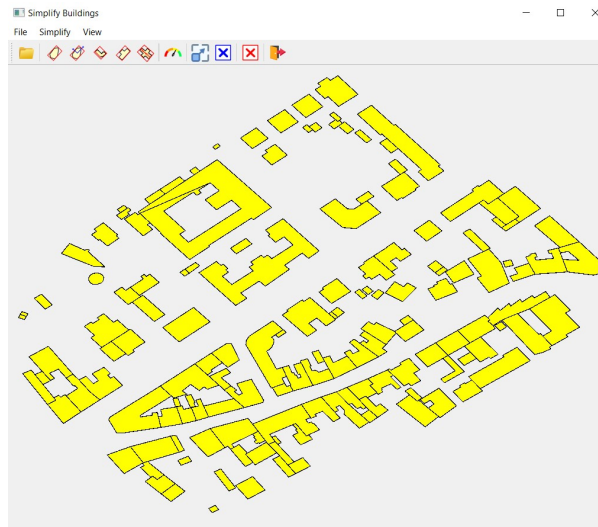


Figure 12: GUI aplikácie



Figure 13: Význam jednotlivých ikon

okna sa vygeneruje tabuľka, ktorú je možné s týmito hodnotami vyexportovať.

Výstupné dáta

Polygóny vykreslené v aplikácii nie je možné exportovať. Miesto toho je možné vyexportovať tabuľku obsahujúcu hodnoty uhlovej odchýlky ($\Delta\sigma_1$) a hodnotu uhlovej odchýlky vo štvorcoch ($\Delta\sigma_2$) v textovom formáte.

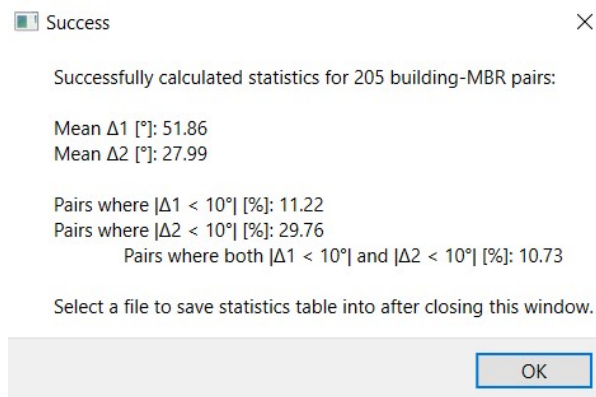


Figure 14: Celkové hodnotenie algoritmu na sade dát

key	delta sigma 1	delta sigma 2
1	33.14	12.6
2	13.68	1.62
3	2.3	0.15
4	107.01	79.77
5	12.16	1.52
6	59.27	25.43

Figure 15: Exportovaná tabuľka

Dokumentácia

Trieda Ui_MainWindow

Trieda UiMainWindow je zodpovedná za celé GUI, ktoré pozostáva z okna, widget a lišty, na ktorej sa nachádzajú ikonky pre zjednodušené ovládanie. Nachádzajú sa tu okrem toho prepojenia jednotlivých ikon s ich funkcionalitami v iných triedach. Funkcie `setupUi()`, `retranslateUI()` boli vytvorené automaticky QT.

`openClick()`

-načíta údaje o polygóne zvolené zvolením súboru cez dialógové okno súboru

generalizationProcess(algo: Callable, algo_name: str)

-overí, či sú údaje použiteľné, pripraví ich, zavolá daný algoritmus MBR, aktualizuje uložené údaje, používané 5 metódami v triede Algorithms.

ratingClick()

-vypočíta efektivitu detekcie hlavného smeru počítača, zobrazí jeho štatistiky a uloží tabuľku štatistík do súboru vybraného pomocou dialógového okna súboru

rescaleClick()

-zmení aktuálne údaje o polygóne na veľkosť okna

clearAllClick()

-vyčistí všetky údaje z Canvas a pamäte programu

clearResClick()

-vymaže iba výsledky

exitClick()

-ukončí program

Trieda IO

Funkcie v tejto triede spracovávajú operácie zodpovedné za načítanie a ukladanie dát. Dialógové okno dovoľí načítať v GeoJSON fomátovaní súbori len s koncovkou *.GeoJSON, *.JSON a *.TXT. Je potrebné, aby tieto dáta boli v S-JTSK (EPSG:5514).

readPnts(pnt_list: list)

-vytvára zoznam n-tíc súradníc

loadBlds(file: str, width: int, height: int)

-načíta dáta zo súboru a preškáluje dáta podľa veľkosti widget

saveTable(file: str, table: PrettyTable)

-uloží tabuľku štatistík účinnosti hlavného smeru a vráti hodnotu typu bool o výsledku ukladania

Trieda Draw

Metódy v tejto triede sú zodpovedné za interakciu používateľa s grafickým užívateľským rozhraním a manipuláciu s vykresľovaním a analýzou objektov. Taktiež obsahuje funkcie typu getter a setter.

__init__(*args, **kwargs)

-konštruktor s predvolenými parametrami potrebnými pre Qt, nastavuje rámec pre kreslenie na widgete

mousePressEvent(e: QMouseEvent)

-eaguje na kliknutie myšou na widget, čo má za následok vykreslenie testovaného bodu alebo bodu do polygónu

paintEvent(e: QPaintEvent)

-obnovuje widget

messageBox(title: str, text : str)

-vytvára dialógové okno s daným textom

clearData()

-nastaví dáta rámca pre kreslenie na predvolené hodnoty

clearMBRs()

-odstráni minimálne ohraničujúce obdĺžniky (MBR)

Trieda Algorithms

Táto trieda implementuje geometrické algoritmy na prácu s polygónmi, so zameraním sa najmä na hľadanie najmenších ohraničujúcich obdĺžnikov (MBR) pre dané polygóny. Na to je potrebné najprv tieto algoritmy definovať, priradiť ku nim ďalšie pomocné metódy (napr. výpočet ulov/plôch), či odstránenie duplicitných bodov. Okrem toho sa tu nachádzajú aj dve výnimky. Prvá ošetruje prípady, kedy budova má menej ako 3 body a druhá zavolalo Error, keď MAER algoritmus spadne. Taktiež sa tu rieši hodnotenie jednotlivých algoritmov a prevod súradníc medzi súradnicovými systémami.

generalize(algo : Callable, blds : dict)

-volá zadaný algoritmus na vytvorenie MBR pre každú predspracovanú budovu, pokiaľ má jej polygón aspoň tri body.

MAER(bld : QPolygonF)

-používa Graham scan algoritmus na vytvorenie konvexnej obálky

PCA(bld : QPolygonF)

-výpočet MBR pomocou metódy Principal Component Analysis

LE(bld : QPolygonF)

-výpočet MBR pomocou metódy Longest Edge algorithm

WA(bld : QPolygonF)

-výpočet MBR pomocou metódy Wall Average algorithm

WB(bld : QPolygonF)

-výpočet MBR pomocou metódy Weighted bisector algorithm

LE_Sigma(bld : QPolygonF)

-nájde najdlhšiu hranu budovy a jej sigma, používané algoritmom Longest Edge

MBR_FromSigma(bld : QPolygonF, sigma : float)

-vytvorí MBR z danej budovy a jej sigma, používané vo všetkých algoritmoch MBR

innerDiags(bld : QPolygonF, diags : dict)

-triedi diagonály danej budovy do kolekcí diagonál vnútri / mimo danej budovy, používané algoritmom Weighted Bisector

windingNum(bld: QPolygonF, q: QPointF)

-spúšťa algoritmus Winding Number pre danú budovu a bod, vráti pozitívny výsledok len v prípade, že bod nie je mimo, na hrane budovy alebo nie je rovnaký ako vrchol budovy

rateAll(blds : dict, mbrs : dict, common: set)

-vypočíta efektivitu detekcie hlavného smeru MBR pre každú kombináciu budovy-MBR.

rateSingle(bld : QPolygonF, mbr : QPolygonF)

-vypočíta efektivitu pre jednotlivú kombináciu budovy-MBR

R(sig : float)

-vypočíta konštantu R z daného sigma MBR, používaného na porovnanie s budovou v metóde rateSingle()

fineCount(values : list)

-vráti počet hodnôt v zozname nižších ako 10, používané v algoritme na hodnotenie efektivity

grahamScan(bld : QPolygonF)

-vypočíta konvexný obal pomocou algoritmu Graham Scan a vráti striktný konvexný obal

get_2line_angle(p_from : QPointF, p_to : QPointF, p_from1 : QPointF, p_to1: QPointF)

-vypočíta uhol dvoch úsečiek v radiánoch

starShapedPolygon(bld: QPolygonF)

-vytvorí hviezdicový polygon z vstupnej budovy a odstráni duplicitný bod, ak majú dva susedné body rovnaký uhol

rotate(mmb : QPolygonF — tuple, sig : float)

-otočí danú Min-Max Box o daný uhol

setInputPol(pol : QPolygonF — tuple)

-vytvorí CCW orientovaný QPolygonF z daného Min-Max Boxu

getArea(bld : QPolygonF — tuple)

-vypočíta plochu vstupných budov

resizeRect(mmb: QPolygonF, build: QPolygonF)

-zmenší daný Min-Max Box, aby sa zhodoval s plochou vstupnej budovy

setCCW_Orientation(blds : dict)

-testuje rotáciu každého polygónu, nastaví ju na proti smeru hodinových ručičiek (CCW), pokiaľ tak nie je

removeDupl(blds : dict)

-vráti danú budovu s jedinečnými bodmi

strictC_Hull(ch : QPolygonF)

-transformuje daný konvexný obal na prísny konvexný obal

halfPlaneTest(p_from : QPointF, p_to: QPointF, p_test: QPointF)

-vráti determinant testu polovice r

minMaxBox(polygon: QPolygonF — list)

-vytvorí Min-Max Box vstupnej budovy

coordDiffDist(p1 : QPointF, p2 : QPointF)

-vypočíta vzdialenosť súradníc v každej dimenzii a ich euklidovskú vzdialenosť

sjtsk2Pixel(point : list, width : int, height : int, x_min : float, x_max : float, y_min : float, y_max : float)

-konvertuje súradnice S-JTSK CRS (EPSG: 5514) na pixelové súradnice

rescaleAll(blds : dict, mbrs : dict, w : int, h : int)

-na základe nových rozmerov preškáluje budovy a MBR, aby sa zmestili do widgetu s posunom 5 pixelov

Výsledky

Na všetky naše datasety boli aplikované algoritmy za účelom detekovania hlavných smerov budov. V tejto časti si popíšeme výsledky jednotlivých algoritmov, ktoré budú ako kvalitatívneho, tak aj kvantitatívneho charakteru. Pri testovaní algoritmov sa hľadelo na ich schopnosť presne identifikovať hlavný smer v rôznych podmienkach. Vďaka tomu je možné určiť výhody, ale aj slabiny jednotlivých algoritmov, čo je dôležité do budúca pri výber vhodného algoritmu pre nejaký dataset.

Dataset Horná

Horná ulica je súčasťou historickej časti mesta, pre ktorú je typická súvislá, na seba často nadvädzujúca zástavba. Budovy tu majú v menšom množstve jednoduchý, ale prevažne komplexný, nekonvexný a veľmi nepravidelný pôdorys. Taktiež sa tu nachádza kruhový pôdorys bašty (historická strážna veža), ale aj pôdorys s vnútorným prsteňom pri väznici. Po väznici má najkomplikovanejší pôdorys budova súdu.

Algoritmus MAER dokázal najlepšie generalizovať najzložitejšie budovy (súd a väznica) a takisto aj jednoduché a pravidelné budovy. V našom prípade ale nedokázal vytvoriť MBR akolo všetkých budov. PCA má dobré výsledky pri rohových budovách, ktoré sa často prejavujú zaobleným rohom. Naopak, čím jednoduchší a pravidelnejší pôdorys budovy (štvorec), tým horší výsledok. Longest Edge má veľmi podobné výsledky ako PCA, avšak pri jednoduchých tvaroch budov má veľmi dobré výsledky. Algoritmus Wall Average dokázal dobre generalizovať väznicu, ale problém mu trochu robili otočené budovy. Weight Bisector sa javí ako najhorší algoritmus pre túto sadu. Výsledky pri komplexných budovách má podobné ako PCA, ale jednoduché budovy generalizuje ešte horšie.

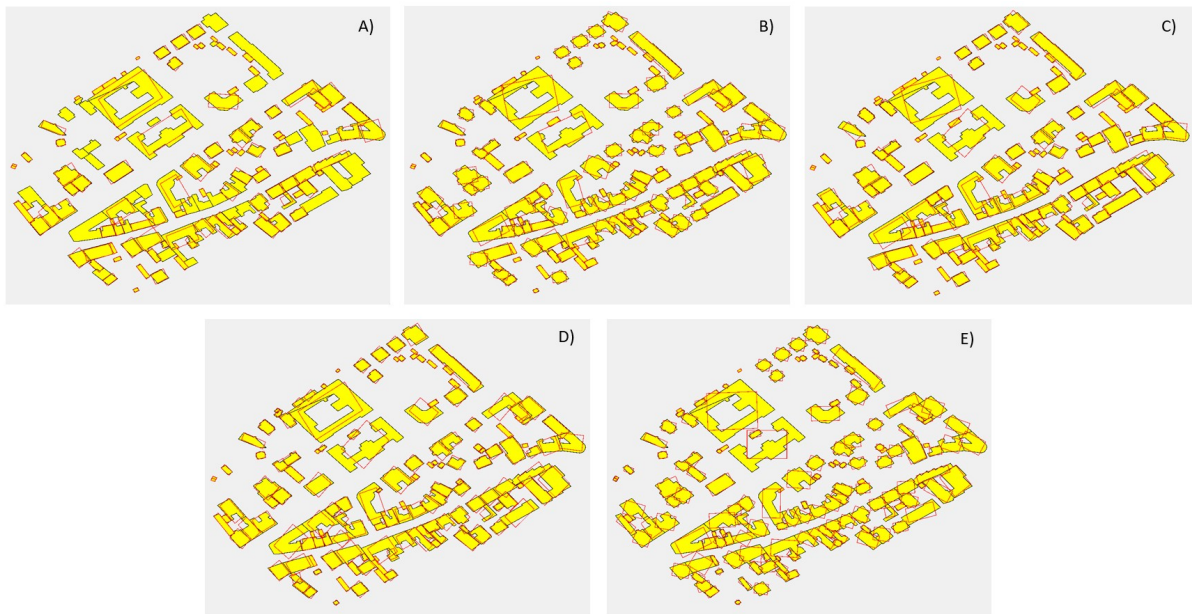


Figure 16: Porovnanie algoritmov na dátovej sade Horná: *MAER* (A), *PCA* (B), *Longest Edge* (C), *Wall Average* (D), *Weight Bisector* (E)

Dataset Uhlisko

Uhlisko je sídlisko, ktoré okrem panelových domov pozostáva aj z rodinných domov. Pôdorysy budov sú oveľa jednoduchšie ako v prípade Hornej ulice a celková hustota zástavby je tu nižšia. Podiel konvexných a nekonvexných tvarov pôdorysu sa javí byť veľmi podobný. Taktiež sa tu nájdú nadvezujúce pôdorysy väčšinou pravidelného tvaru a jedná sa hlavne o garáže, či iné prístavby ku rodinným domom. .

Väčšie množstvo budov mali podlhovastý tvar, ktorý dokázali algoritmy MAER, PCA a Longest Edge generalizovať veľmi dobre. Netreba však zabudnúť, že MAER opäť nebol schopný generalizovať všetky budovy a PCA mala opäťovne problém pri pravidelných tvaroch, ale teraz v menšom množstve. Pre tento tvar budov sa javí byť najhorší Wall Average. Garáže predstavovali podlhovastý pôdorys (tvar schodov), ktorý nedokázali dobre generalizovať Wall Average ani Longest Edge. V tejto sade ukázal potenciál Weight Bisector a jeho výsledky boli dramaticky lepšie ako pri sade Horná. Problémy mu ale robili kosodĺžniky. Ak odmyslíme generalizovanie garáží, tak Longest Edge sa javí byť ako najlepšia metóda pre generalizovanie tejto sady.

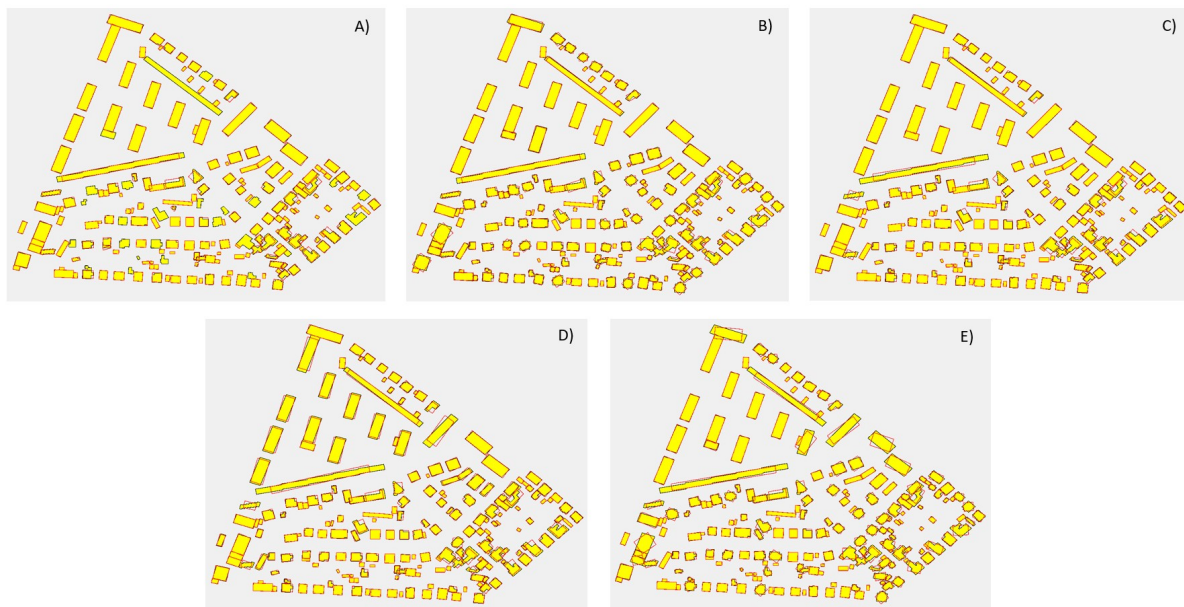


Figure 17: Porovnanie algoritmov na dátovej sade Uhliko: *MAER* (A), *PCA* (B), *Longest Edge* (C), *Wall Average* (D), *Weight Bisector* (E)

Dataset Lazy

Lazy predstavujú roztrúsené osídlenia v horskej oblasti. Z toho dôvodu je hustota zástavby oveľa nižšia a komplexnosť tvaru budov oveľa jednoduchšia ako v predchádzajúcich dvoch datasetoch. Taktiež sú tu na seba nadväzujúce polygony predstavujúce prístavby ku domom, prípadne sa jedná o zlu segmentáciu dudovy.

Budovy tu majú prevažne jednoduchý tvar a zopár z nich sa podobá písmenu L. To robilo problém pre algoritmy Longest Edge a Weight Bisector. Podobne ako v predchádzajúcich datasetoch, tak aj tu má PCA problémy pôdorysmi v tvare štvorcov. Zvyšné algoritmy sa na prvý pohľad javia mať dobré výsledky.

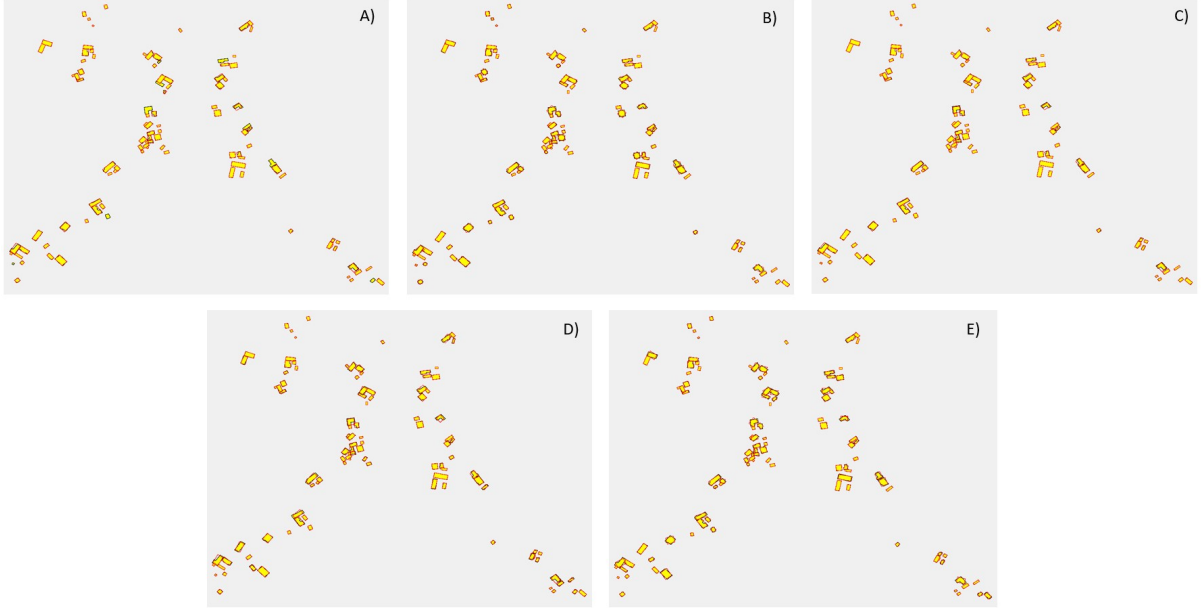


Figure 18: Porovnanie algoritmov na dátovej sade *Lazy:MAER* (A), *PCA* (B), *Longest Edge* (C), *Wall Average* (D), *Weight Bisector* (E)

Zhrnutie výsledkov

Kvalitatívny spôsob hodnotenia výsledkov nie je objektívny a je potrebné sa pozrieť na výsledky v číslach. Za týmto účelom boli vypočítané hodnoty uhlovej odchýlky ($\Delta\sigma_1$) a hodnotu uhlovej odchýlky vo štvorcoch ($\Delta\sigma_2$), pričom v praxi sa akceptovávajú objekty s hodnotou tohto uhla menšieho ako 10. Tento údaj bol následne vyjadrený aj v percentách (podiel párov splňujúcich túto podmienku).

$$\Delta\sigma_1 = \frac{\pi}{2n} \sum_{i=1}^n [r_i - r],$$

$$\Delta\sigma_2 = \frac{\pi}{2n} \sqrt{\sum_{i=1}^n (r_i - r)^2}.$$

$$r_i = (k_i - \lfloor k_i \rfloor) \frac{\pi}{2},$$

$$k_i = \frac{2\sigma_i}{\pi}.$$

My sme sledovali hodnotu $\Delta\sigma_2$ pri všetkých algoritmoch, pretože dosahovala najvyššie hodnoty. Na základe týchto údajov konštatujeme, že algoritmus Wall Average sa javí byť najlepší naprieč všetkými testovanými metódami. Najhorším algoritmom je Weight Bisector a neuspokojivé čísla má aj PCA. Pri zvyšných dvoch (MAER, Longest Edge) algoritmoch sledujeme efektivitu pre všetky datasety v priemere nad 80%, čo je taktiež veľmi dobrý výsledok a dokonca tieto dve metódy mali v datasete Uhlisko o čosi lepšie výsledky ako Wall Average.

Algoritmus	Horná	Uhlisko	Lazy	Priemer
<i>PCA</i>	48,95	61,54	57,14	55,88
<i>MAER</i>	80	92,73	72,92	81,88
<i>Wall Average</i>	90,21	92,31	79,05	87,19
<i>Longest Edge</i>	82,52	93,71	76,19	84,14
<i>Weight Bisector</i>	24,48	56,64	57,14	46,09

Table 1: Efektivita ($\Delta\sigma_2 < 10^\circ$) algoritmov v datasetoch

Záver

Témou tohto zadania bol problém generalizovanie rôdorysu budov. Bolo potrebné vytvoriť konvexnú obálku použitím Graham Scan, po ktorom boli použité algoritmy na určenie hlavného smeru konvexnej obálky. Konkrétne PCA, MAER, Longest Edge, Wall Average a Weight Bisector. Funkčnosť týchto algoritmov bola otestovaná na troch datasetoch s rozličnou štruktúrou a hustotou zástavby. Okrem toho boli ošetrené singulárne prípady pri vytváraní konvexnej obálky. Celá analýza prebiehala v našej aplikácii, ktorú sme vytvorili za pomoci knižnice QT a programovacieho jazyka Python.

Naša aplikácia bola vylepšená o funkciu rescale, ktorá umožňovala čo maximálne pokrytie polygónov na widget (pokiaľ polygón zaberá iba malú časť widget, tak sa zväčšil na čo najväčšiu plochu).

Pri tvorbe našich datasetov sme sa stretli s viacerými problémami. Prvým bol prevod súradníc z WGS84 do S-JTSK, ktorý nebolo možné vykonať v rezortnej transformačnej službe, čo sme vyriešili zmenou súradnicového systému pri exporte súboru z QGis. Ďalej pri exporte GeoJSON s QGis bol vytvorený súbor, ktorý mal o jednu hranatú zátvorku viac (4) ako ArcGis (3). Pre načítanie dát do našej aplikácie tak bolo potrebné túto zátvorku odstrániť pri každom prvku.

Pri algoritme MAER sme sa stretli s problémom, ktorý sa nám nepodarilo vyriešiť. Tento problém sa prejavoval nevytvorením MBR pre niektoré budovy v datasete z dôvodu chyby vo framework. Celkovo tak nebolo v našich datasetoch generalizovaných 33 budov v datasete Horná, 25 budov na Uhlisku a 9 budov na lazoch. Preto treba brať presnosť tohto algoritmu s rezervou a reálna presnosť sa môže líšiť.

Analýzou výsledkov sme prišli ku záveru, že pre naše datasety je najvhodnejšie použiť algoritmus Wall Average, ktorého priemerná presnosť pre všetky sady dát bola 87,19%. Naopak najhorším algoritmom je Weight Bisector s presnosťou len 46,09%.

Zoznam použitej literatúry

- 3DBuildings. 2020. How building data works: Level of Detail. [online] dostupné na: <https://3dbuildings.medium.com/how-building-data-works-level-of-detail-e9bad0b61baa> [cit. 20-04-2024]
- Berg, M et al. 2008. Computational Geometry. Berlin: Springer-Verlag, 2008. 378s. ISBN 978-3-540-77973-5
- BAYER, T. (2008). The importance of computational geometry for digital cartography. Geoinformatics FCE CTU, Praha, vol. 3, s.15-24.
- BAYER, T. Katedra aplikované geoinformatiky a kartografie. Přírodovědecká fakulta UK, Albertov 6, Praha. 2024. Point Location Problem. Prednáška z predmetu: Algoritmy počítačovej kartografie [cit. 19-04-2024]
- JAADI, Z. 2024. A Step-by-Step Explanation of Principal Component Analysis (PCA). [online] dostupné na: <https://builtin.com/data-science/step-step-explanation-principal-component-analysis> [cit. 20-04-2024]
- ROURKE, O. J. 1998. Computational Geometry in C. Cambridge: Cambridge University Press, 1998. 376s. ISBN: 9780521640107s
- TRHAN, O. 2017. Úprava digitálneho modelu povrchu získaného pomocou UAV fotogrametrie. Geografický a kartografický obzor, Praha, roč. 63 (105), č. 9, s.177–196. ISSN 1805-7446
- VIOLENTYEV, A. 2020, Convex Hull Algorithm: *Graham Scan and Jarvis March tutorial*, [Youtube] dostupné na: <https://www.youtube.com/watch?pp=desktop&v=B2AJoSzf4M> [cit. 18-04-2024]